

# 两种实现方法 分为传统机器视觉方案和深度学习方案

## 传统视觉方案：

缺陷区域提取根据缺陷类型分为点状及线性缺陷提取、爆边缺陷提取

### 1、点状&线性缺陷提取

预处理之后的图片通过边缘提取（传统边缘检测算法如 Robert、Sobel、Krisch、Canny 算子等或形态学提取），获取到缺陷候选区域，再将其输入到分类网络（级联 BP 网络、SVM 分类器、多层卷积+全连接网络）中进行筛选分类检测。

### 2、爆边缺陷提取

先进行边缘提取（掏空法&边缘跟踪法，后一种方法速度和精度都要优于第一种方法），然后根据边缘与最小外接矩阵差值，设计算法进行爆边缺陷位置及大小检测。

## 深度学习方案：

预处理之后的图片导入深度学习网络

### 1、Faster-R-CNN

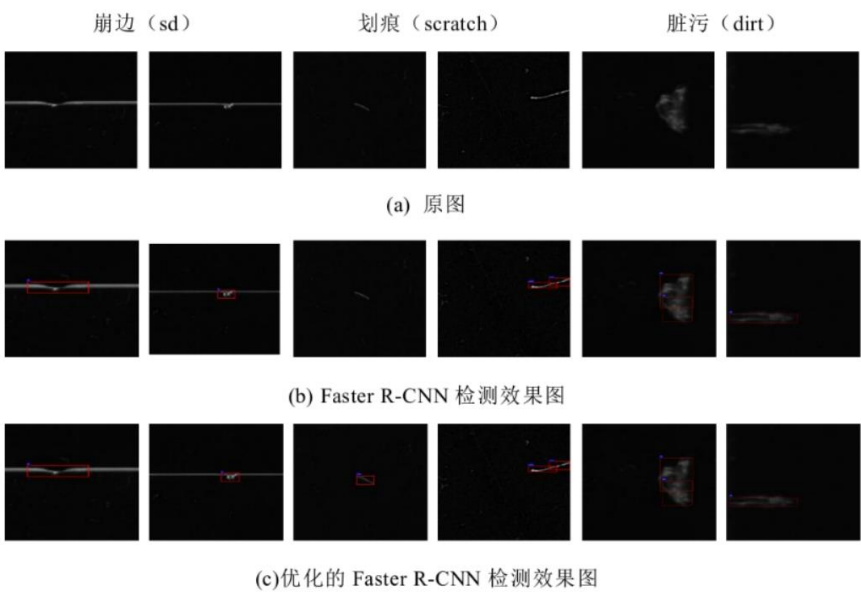



图 4-4 部分检测效果图

2、SSD



(b) 改进后的 SSD 检测效果图  
图 4-13 改进的 SSD 部分检测效果图

3、两种方案对比




图 4-18 每张图片检测时间曲线图

曲线 a 为 Faster R-CNN 检测每张样本图片所需时间的曲线图，曲线 b 为改进前 SSD 所需时间曲线图，曲线 c 为优化后 Faster R-CNN 所需时间曲线图，曲线 d 为改进后 SSD 所需时间曲线图。

Table 4-3 AP and mAP values (%) detected by different models

目标检测模型	Faster R-CNN	优化后的 Faster R-CNN	SSD	改进的 SSD
划痕 AP 值	83.5	88.2	88.7	90.7
崩边 AP 值	89.9	92.6	83.9	88.9
脏污 AP 值	88.5	91.9	86.6	91.3
mAP	87.3	90.9	86.4	90.3

Faster R-CNN 以牺牲检测速度来提高检测精度，而改进后的 SSD 在保证检测实时性的前提下提升了检测精度。

检测结果展示



图 5-4 崩边缺陷识别效果

Fig 5-4 identification effect of sd




图 5-5 划痕缺陷识别效果

Fig 5-5 identification effect of scratch




图 5-6 脏污缺陷识别效果

Fig 5-5 identification effect of dirt